

Agente de execução condicionado a fluxo de ordens: separando ganho de decisão de hipótese de preenchimento

Programa BTG Alpha Lab · Edital 01/2026 · Linha 3: desenvolvimento de agentes de execução ótima

Murilo Rodrigues de Souza

1. Problema e relevância

Toda ordem institucional enfrenta o mesmo dilema: cruzar o spread garante execução e paga o atrito; esperar economiza o atrito e arrisca executar pior. Os modelos de referência tratam a intensidade de negociação como função do tempo e do inventário [1,6,7], e o aprendizado por reforço aplicado à execução herda essa estrutura de estado [2,3,4]. Falta uma política que decida agressividade a partir de um estado observável do fluxo e seja avaliada com hipóteses de preenchimento declaradas em vez de presumidas.

O desequilíbrio de fluxo é o candidato natural a esse estado [6]. A pergunta não é se ele prevê preço, e sim se a previsão sobrevive ao custo de agir sobre ela — questão aguda na B3, onde o spread cotado mediano do IBOV é de 5,21 bps.

2. Evidência preliminar com o BTG-TLD-A26

Processei os cinco pregões completos — 85 ativos, 8,86 milhões de negócios — em barras de um minuto por ativo-pregão, com conversão de fuso e ordenação desempatada por seq_num. O OFI é o volume líquido agredido, normalizado pelo volume da barra e discretizado em três estados por terços amostrais.

Medindo o retorno seguinte pelo preço do último negócio, pressão compradora aparecia seguida de queda, com $t = 6,28$ sobre 112.740 observações — forte e inteiramente espúrio: a agressão de compra executa no ask, o negócio seguinte sai no bid, e o preço medido cai sem que o mercado tenha se movido. Refeita a medida sobre o ponto médio do livro, disponível em top_px_bid e top_px_offer, o sinal inverte e indica continuação, como descreve a literatura de impacto [6]: $P(\text{alta} \mid \text{movimento})$ vai a 0,5197 após pressão compradora e 0,4784 após pressão vendedora, com z de ± 8 .




Figura 1. (a) O mesmo estado prevê queda em preço de negócio e alta em ponto médio. (b) Sinal contra meio spread por quartil de liquidez. (c) Walk-forward por pregão, cortes estimados só no treino.

Fora da amostra, com cortes treinados nos pregões anteriores, o retorno médio é de +0,42 bps por barra, positivo nos quatro folds (t entre 2,5 e 6,9); 23 dos 85 ativos têm t acima de 2 e nenhum abaixo de -2 , contra 4,2 esperados por acaso.

E ainda assim ele não paga execução agressiva. Cruzar custa 2,60 bps por lado na mediana do índice, e a razão entre sinal e meio spread fica entre 0,06 e 0,14 conforme a liquidez. Um sinal dessa magnitude não gera estratégia direcional, mas pode mudar a decisão de quem precisa executar de todo modo e escolhe apenas quando esperar, postar ou cruzar.

3. Baselines de execução: segundo resultado preliminar

Simulei 1.343 ordens de compra — 85 ativos, quatro pregões de teste, quatro janelas diárias, horizonte de 30 minutos — com hipótese de preenchimento declarada: execução agressiva, preenchimento certo, custo de meio spread por fatia, benchmark no ponto médio de chegada e cortes de estado vindos só dos pregões anteriores.

Política de agendamento (contra TWAP)	Ganho (bps)	t
Fluxo, $k = 0,5$	+0,277	+3,26
Fluxo, $k = 1,0$	+0,597	+3,23
Regra escolhida em dois pregões, avaliada nos dois seguintes	-0,438	-3,56

O resultado é positivo e instável, e a instabilidade é o achado. O agendamento condicionado supera o TWAP em 0,3 a 0,6 bps (t acima de 3), mas a regra vencedora em dois pregões perde nos dois seguintes. Mais revelador: a primeira versão do simulador normalizava os pesos pela janela inteira, deixando a decisão de hoje depender de sinais futuros; corrigido o vazamento, o sinal da melhor regra se inverteu. Um mapeamento fixo entre fluxo e agressividade, escolhido à mão, não é robusto — e é por isso que o problema pede um agente que o aprenda sob restrições, e um protocolo que separe decisão de artefato de simulador.

4. Pergunta de pesquisa e hipóteses

Pergunta: Um agente que condicione a execução de uma ordem-alvo ao estado de fluxo de ordens, além de tempo e inventário, reduz o implementation shortfall frente a TWAP, VWAP, POV e Almgren–Chriss — e que fração desse ganho sobrevive quando a hipótese de preenchimento do simulador é variada dentro do que os dados de livro permitem?

H1. O estado de fluxo informa a decisão além de tempo e inventário; a ablação sem essa variável mede seu valor marginal. H2. O ganho não é artefato do modelo de preenchimento: sob modelos de fila distintos, calibrados em dados reais de livro, a vantagem persiste em ordem e magnitude. H3. A política generaliza para ativos não vistos e datas posteriores; falha aqui indica memorização do replay, não política de execução.

Critério de sucesso, fixado antes dos experimentos. H1 exige ganho de 0,5 bps da ablação com fluxo sobre a sem fluxo, t acima de 3 em no mínimo 2.000 ordens por regime de preenchimento, preservado em três dos cinco ativos. H2 exige mesmo sinal e metade da magnitude nos três modelos de preenchimento. H3 exige vantagem sobre POV em ativos fora do treino com t acima de 2. Abaixo disso o resultado é negativo, não tendência.

H2 distingue esta proposta de um exercício de aprendizado por reforço: um agente treinado em replay aprende a explorar o simulador tanto quanto o mercado, e a literatura raramente separa as duas contribuições. Aqui o resultado é reportado como intervalo entre modelos de preenchimento, não como número único.

5. Dados

O BTG-TLD-A26 traz, além dos negócios, o topo do livro no instante de cada execução: permite medir spread, classificar o lado agressor de forma independente e medir retorno em ponto médio. Seus 85 ativos dão poder ao teste transversal e sustentam as curvas de volume que calibram VWAP e POV.

O BTG-OBD-A26 traz o livro em nível de mensagem para cinco ações em 18 pregões, com dez níveis, identificador de ordem e posição em fila — 14 milhões de eventos. Permite um replay em que o preenchimento passivo decorre de prioridade preço-tempo reconstruída, não de regra arbitrária; os cinco papéis também estão no TLD.

O BTG-ATS-A26 cobre WIN, WDO e DI1 em 2.461 pregões entre 2016 e 2025, e permite o teste que 18 pregões não sustentam: se os regimes intradiários de volume e volatilidade persistem por uma década.

6. Método

Formulação. Processo de decisão de Markov em horizonte finito. Estado: inventário, tempo restante, estado de OFI, volatilidade, spread e posição na fila. Ações: esperar, postar no topo, melhorar preço ou cruzar, com a fração a enviar. Recompensa: shortfall incremental contra o ponto médio de chegada, com penalização de variância e custo terminal. Participação máxima, inventário zerado ao fim e limite de ordens são restrições, não penalidades.

Especificação. Ordem-alvo de 0,5% a 2% do volume diário, horizonte de 30 minutos em barras de um minuto, participação máxima de 10% por barra. Discretização inicial: inventário em cinco faixas, tempo em seis, fluxo em três estados e spread em dois — 180 estados e quatro ações, compatível com os cerca de 3.500 episódios que 18 pregões e cinco papéis produzem.

Agente. Iteração de política sobre esses estados, produzindo tabela de decisão auditável com poucos parâmetros — condição para que a comparação signifique algo em 18 pregões. Sobre essa referência avaliam-se um agente com aproximação de função e a destilação a partir de oráculo com informação futura [3], que reduz variância em horizontes curtos. O critério para adotar modelo mais complexo é ganho fora da amostra, não capacidade [4].

Baselines e ablações. TWAP, VWAP, POV e Almgren–Chriss [1], sob as mesmas regras de replay, custo e participação; a ablação decisiva é o mesmo agente sem a variável de fluxo.

Separação entre decisão e preenchimento. O modelo de fila de Cont, Stoikov e Talreja [7], cuja aderência à B3 foi avaliada em [10] sobre o próprio BTG-OBD-A26, fornece o preenchimento de referência. A mesma política é reavaliada sob três regimes — fila reconstruída evento a evento, CST homogêneo e CST condicionado ao fluxo, que endereça a limitação de agrupamento temporal apontada por [8]. Reporta-se o intervalo entre eles; vantagem que só exista no regime mais permissivo é registrada como artefato.

Prevenção de vazamento e generalização. Nenhuma variável de estado usa informação posterior à decisão e a agenda é causal — o erro que a Seção 3 documenta. Validação dupla, walk-forward por data e cruzada por ativo; a checagem de duas definições de preço aplica-se a toda métrica de custo.

7. Cronograma de seis meses e entregáveis

M1–M2. Ambiente de replay sobre o BTG-OBD-A26 com livro reconstruído e prioridade preço-tempo; baselines TWAP, VWAP, POV e Almgren–Chriss sob regras idênticas; sinal de fluxo validado nos 85 ativos do TLD e nos cinco do OBD. M3. Três modelos de preenchimento — fila reconstruída, CST homogêneo e CST condicionado ao fluxo — com análise de aderência. M4–M5. Agente tabular, depois com aproximação de função e destilação; ablação sem fluxo; validação walk-forward e cruzada por ativo; robustez de regimes com o BTG-ATS-A26; decomposição decisão versus preenchimento. M6. Consolidação e redação. Entregáveis por etapa: ambiente e relatório de baselines, modelos calibrados, política auditável, relatório de validação e, ao fim, artigo ou relatório acadêmico com pacote reproduzível nos ambientes autorizados.

8. Riscos e mitigação

O agente aprende o simulador, não o mercado. Risco central de agentes treinados em replay, e a razão de a separação decisão/preenchimento ser hipótese e não apêndice. Mitigação: três modelos de preenchimento, ablação sem fluxo, política inicial auditável e descarte de vantagens que não sobrevivam ao regime mais conservador.

Amostra estreita para treinar. Cinco papéis e 18 pregões limitam a capacidade treinável sem memorização. Mitigação: política tabular de poucos parâmetros, sinal estimado nos 85 ativos do TLD e aproximação de função apenas com ganho em ativos não vistos.

Sobreposição com trabalho já realizado pelo Programa. Mitigação: o projeto não reestima o CST de [8]; usa-o como baseline e testa a extensão que aquele trabalho deixa em aberto — condicionamento ao agrupamento temporal — dentro de um problema de decisão.

9. Contribuição esperada

Três contribuições. A primeira é um teste direto da explicação que [8] oferece para a própria limitação: se o desvio entre o CST e o mercado brasileiro vem do agrupamento temporal do fluxo, intensidades condicionadas ao fluxo devem reduzi-lo e melhorar a decisão de um agente que as utiliza — a hipótese é dos autores, o teste não. A segunda é o protocolo de decomposição entre ganho de decisão e ganho de hipótese de preenchimento, que a literatura de execução por aprendizado raramente separa e que a evidência preliminar mostrou ser decisivo. A terceira é empírica: a primeira medida, em dados brasileiros de livro em nível de mensagem, de quanto um sinal de fluxo de 0,4 bps se converte em redução de shortfall sob preenchimento realista. Ficam como subprodutos o ambiente de replay, os baselines calibrados para a B3 e a variável de fluxo validada em 85 ativos.

Toda a análise preliminar foi construída por mim durante a elaboração desta proposta: leitor de Parquet em Python puro, ingestão em streaming, extração de fluxo, modelagem markoviana, baselines de execução e o arcabouço de validação. Os dois achados metodológicos mais importantes foram negativos — o bid-ask bounce que invertia o sinal e o vazamento que invertia o melhor agendamento —, e é essa disciplina, aplicada à separação entre decisão e simulador, que o projeto propõe manter.

Referências

- [1] Almgren, R. and Chriss, N. Optimal execution of portfolio transactions. *The Journal of Risk*, 3(2):5–39, 2001.
- [2] Nevmyvaka, Y., Feng, Y. and Kearns, M. Reinforcement learning for optimized trade execution. *ICML*, 673–680, 2006.
- [3] Fang, Y. et al. Universal trading for order execution with oracle policy distillation. *AAAI*, 35(1):107–115, 2021.
- [4] Zhang, C. et al. Towards generalizable reinforcement learning for trade execution. *IJCAI*, 4975–4983, 2023.
- [5] Fang, Y. et al. Learning multi-agent intention-aware communication for optimal multi-order execution in finance. *KDD*, 4003–4012, 2023.
- [6] Cont, R., Kukanov, A. and Stoikov, S. The price impact of order book events. *Journal of Financial Econometrics*, 12(1):47–88, 2014.
- [7] Cont, R., Stoikov, S. and Talreja, R. A stochastic model for order book dynamics. *Operations Research*, 58(3):549–563, 2010.
- [8] Teixeira, B., Avila, R., Costa, O. and Maciel, L. Semi-analytical latency-aware distributional inference for limit order books. *EBFin*, 2026.
- [9] Código da análise preliminar (leitor de Parquet em Python puro, pipeline de fluxo, simulador de execução): <https://github.com/MuriloDevPj/pipeline-tld-parquet-BTG>